



Михайлов Алексей

Мужчина, 27 лет, родился 20 июля 1999

+7 (919) 8181571

mihalovish@yandex.ru — предпочитаемый способ связи

Проживает: Санкт-Петербург, м. Парк Победы

Гражданство: Россия, есть разрешение на работу: Россия

Не готов к переезду, готов к командировкам

Желаемая должность и зарплата

ML engineer

Специализации:

— Программист, разработчик

Тип занятости: полная занятость, частичная занятость, проектная работа/разовое задание

Формат работы: удалённо, гибрид, на месте работодателя

Желательное время в пути до работы: не имеет значения

Самозанятость: Нет

Медкнижка: Есть

Опыт работы — 4 года

Февраль 2026 —
настоящее время
8 месяцев

МПК Софт

Санкт-Петербург

Инженер-программист 1 категории

* Внедрил AI-агентов на базе LangGraph в процессы CI/CD для автоматизации инженерных задач разработки и сопровождения ПО.

* Реализовал пайплайны автоматической генерации unit-тестов для C++-проектов, что позволило ускорить покрытие кода тестами и повысить надежность изменений.

* Разработал автоматизированные скрипты сборки проектов, диагностики ошибок и первичного исправления дефектов кодогенерации.

Февраль 2025 —
Февраль 2026
1 год 1 месяц

БСС ИИ

Санкт-Петербург, bssys.com/

Инженер исследователь

* Проводил сравнительный анализ и бенчмаркинг актуальных LLM, оценивал метрики качества ответов, скорость генерации токенов и throughput/latency для выбора оптимальных решений под конкретные бизнес-задачи. Также сравнивал разные бэкенды по качеству работы и стабильности выдаваемых результатов. Занимался подготовкой и оптимизацией инференса моделей.

* Осуществил полную миграцию инфраструктуры развертывания нейросетей на Triton Inference Server, что позволило унифицировать обслуживание моделей, оптимизировать использование видеопамати через динамическое батчирование и обеспечить высокую доступность сервисов.

* Настраивал инференс с использованием различных современных движков вывода: внедрял vLLM там где это получалось по ИБ, применял llama-cpp для эффективного квантования и запуска новых сырых моделей на различном оборудовании, а также развертывал локальные среды с помощью Ollama

Июль 2023 —
Февраль 2025

ОКАС

1 год 8 месяцев

Санкт-Петербург

Инженер машинного обучения

- * Ресерч моделей Automatic speech recognition для режима работы online.
- * Реализация статей, апробация, эксперименты, сбор метрик.
- * Деплой моделей, поливание github репозитория, рефакторинг кода.
- * Создание производительных сервисов инфера для бизнеса
- * Создание сервисов (в argo workflow и других оркестраторах) по fi-tuning и distillation для моделей ASR для многоразового использования.
- * Переписывание опенсорс пайпланов под мульти-GPU обучение и работу с большими датасетами
- * Аналитика, активное участие в обсуждениях с бизнесом вектора развития сервисов распознавания речи
- * Конвертация моделей в onnx и переписывание логики сервиса под новые нужды
- * работа с ASR внутри экосистемы от nvidia (nemo, nemo2riva, riva): подгон docker сервисов с triton бекендом от nvidia для развёртывания в нашем kubernetes, настройка пайплайнов через riva-build автоматический генератор конфигов, прикручивание языковой модели, обучение моделей внутри фреймворка nemo, конвертация из nemo в riva формат

Полученные результаты:

В прод выкачен с нуля собранный мной сервис для распознавания речи в стриминговом режиме. Проведён весь цикл работ от ресерча и обучения до деплоя.

Май 2022 —
Январь 2023
9 месяцев

Sber Robotics Labs

Санкт-Петербург

Инженер

- * Разработал и обосновал алгоритм диспетчеризации склада, включая проработку структуры склада, математическую модель и алгоритмическую логику в соответствии с техническим заданием.
- * Участвовал в формировании и защите концепции инженерного решения на стадии проектирования. Выполнял разработку на Python и моделирование в Matlab, регулярно проводил презентации промежуточных результатов
- * Проводил научный поиск актуальных решений, анализировал аналоги и оценивал их применимость к заданной складской структуре.
- * Участвовал в НИР, выполнял математическое обоснование эффективности предложенных алгоритмов и отсутствие сопоставимых альтернатив.
- * Сравнивал существующие решения и обосновывал выбор симулятора для дальнейших экспериментов с учетом требований проекта.

Образование

Магистр

2026
Магистр

Сибирский федеральный университет, Красноярск

программная инженерия, реинжиниринг бизнес процессов

2023
Высшее

Санкт-Петербургский национальный исследовательский университет информационных технологий, механики и оптики, Санкт-Петербург

ИИТ, Инженерия машинного обучения(магистратура)

2022
Высшее

Санкт-Петербургский национальный исследовательский университет информационных технологий, механики и оптики, Санкт-Петербург

СУИР, Робототехника и искусственный интеллект(магистратура)

2021
Высшее

Санкт-Петербургский национальный исследовательский
университет информационных технологий, механики и оптики,
Санкт-Петербург
ПИИКТ, Нейротехнологии и программирование(бакалавриат)

Повышение квалификации, курсы

2023	NLP-course. Spring 2023 ods.ai
2023	Курс "Docker" LMS carpov.courses
2023	Продвинутый Python Университет ИТМО
2022	Фронтиры прикладного искусственного интеллекта: промышленность, экономика, образование Университет ИТМО
2021	Организация предпринимательской деятельности (диплом о получении профессиональной переподготовки) Университет ИТМО

Навыки

Знание языков	Русский — Родной Английский — B2 — Средне-продвинутый
Навыки	Искусственный интеллект Работа с большим объемом информации Docker NLP Transformers BERT asyncio ASR iohttp FastAPI k9s minio harbor s3 Spark PyTorch pytorch-lightning Hadoop Python C++ SQL polars llamacpp Linux Git langchain langgraph RAG Kubernetes